



## **PROJE**

**BLM3051 - Yapay Zeka 2024/2**

**Öğrenci Adı: Ozan Orhan**

**Öğrenci Numarası: 21011077**

**Dersin Öğretmeni: Mehmet Fatih Amasyalı**

**Video Linki: <https://youtu.be/nAgE46c8bXY>**

**Giriş** Bu proje, 25×25 boyutlu binary matris girişlerine karşılık beş farklı yapay sinir ağı (YSA) modeli eğitilmesini ve performanslarının incelenmesini amaçlamaktadır. Her problemde 800 eğitim ve 200 test örneği üretilmiş; veri üretimi, hiperparametre optimizasyonu, model eğitimi, erken durdurma, ve sonuçların grafiksel sunumu adım adım gerçekleştirilmiştir.

## Proje Amacı

Problem A: Matriste rastgele 2 nokta; model bu iki nokta arasındaki Öklid mesafesini tahmin edecek.

Problem B: 3–10 nokta; model en yakın iki nokta arasındaki mesafeyi tahmin edecek.

Problem C: 3–10 nokta; model en uzak iki nokta arasındaki mesafeyi tahmin edecek.

Problem D: 1–10 nokta; model nokta sayısını tahmin edecek.

Problem E: 1–10 kare (değişken boyutta ve konumda); model kare sayısını tahmin edecek.

Her problem için MLP tabanlı bir model kullanıldı; MLP tercih edilme sebepleri:

Basit ve hızlı prototipleme imkânı,

Matris verisini düzleştirilmiş vektör formunda doğrudan kullanabilme,

Lineer ve hafif doğrusal olmayan ilişkileri öğrenme kapasitesi,

Karmaşık mimarilere kıyasla daha az hesaplama yükü. hiperparametre optimizasyonu grid-search ile; eğitim verisinin çeyrek (%25), yarım (%50) ve tam (%100) alt-kümeleriyle karşılaştırmalı performans ölçüldü.

## Yöntem

**NumPy:** Veri üretimi için matris işlemleri ve rastgele sayı üretimi.

**PyTorch (torch):** Model tanımı, eğitim döngüsü, optimizasyon ve GPU hızlandırma.

**torch.nn:** Sinir ağı katmanları (Linear) ve aktivasyon fonksiyonu (ReLU).

**torch.optim:** Adam optimizasyon algoritması.

**torch.utils.data:** TensorDataset ve DataLoader ile verinin yüklenmesi ve batch işlemleri.

**matplotlib.pyplot:** Eğitim süreci ve performans grafiklerinin çizilmesi.

**itertools.product:** Hiperparametre kombinasyonlarının grid-search ile oluşturulması.

## MLP NEDİR?

Çok Katmanlı Algılayıcı (MLP), birden fazla tam bağlantılı katmandan oluşan beslemeli sinir ağıdır. Giriş, gizli ve çıkış katmanlarından oluşur. ReLU gibi aktivasyonlarla doğrusal olmayan ilişkileri öğrenebilir.

## PERFORMANS ÖLÇÜTLERİ

**MSE (Mean Squared Error):** Kare hataların ortalaması.

**MAE (Mean Absolute Error):** Mutlak hataların ortalaması.

**Veri Üretimi:** generate\_data\_\* fonksiyonları her problem özelinde rasgele noktalar/kareler oluşturdu; matrisler 625 boyutlu vektör şeklinde düzleştirildi; etiketler (mesafe veya sayım) hesaplandı.

**Tekrarlanabilirlik:** SEED=42 sabitlenerek hem NumPy hem PyTorch rastgele tohumları ayarlandı.

**Hiperparametre Optimizasyonu:** Öğrenme oranı (lr), gizli katman boyutu (hidden\_size) ve batch\_size için grid-search (2×2×2 kombinasyon) kullanıldı. 80/20 eğitim-doğrulama ayırımıyla 20 epoch değerinin MSE'si en düşük olan parametreler seçildi.

**Model Eğitimi:** Seçilen hiperparametrelerle her split (%25, %50, %100) için MLP eğitildi. **Erken durdurma** (patience=5) ile test MSE'si iyileşmeyince eğitim kesildi, böylece aşırı öğrenme önendi. Seçilen hiperparametrelerle her split (%25, %50, %100) için MLP eğitildi. Erken durdurma (patience=5) ile test MSE'si iyileşmeyince eğitim kesildi.


**Performans Ölçütleri:** Her epoch için test MSE; eğitim sonunda test MAE ve MSE hesaplandı.

**Görselleştirme:** Epoch-başı MSE ve split-sonu MAE/MSE grafikleri .png olarak kaydedildi.


**Hata Analizi:** Test setindeki ilk 10 örnek için gerçek-tahmin farkları listelendi

## Bulgular ve Yorumlar:


**A:**




Bu eğri, modelin az sayıda örnekle mesafe ilişkisini çabuk öğrendiğini, ancak veri sınırlı olduğu için MSE'yi yaklaşık 50'nin altına düşüremediğini gösteriyor. Erken durdurma için epoch 35–40 arası uygun bir nokta oluşturuyor.



Bu, modelin daha fazla veri ile hem daha hızlı hem de daha düşük hataya ulaştığını gösteriyor. Erken durdurma için 18–20. epoch arası uygun bir durma noktası sunuyor.



Bu, tam veriyle modelin hem çok daha hızlı hem de daha düşük bir hataya ( $\approx 40$ ) ulaştığını; erken durdurma için 8–10. epoch aralığının ideal olduğunu gösterir.



Yani hem MAE hem de MSE, eğitim seti büyüdükçe düzenli olarak azalıyor—daha fazla veri, modelin mesafe ilişkisini daha doğru öğrenmesini sağlıyor.

```
Saved E_train.txt and E_test.txt
[HP] Best for A: {'lr': 0.001, 'hidden_size': 128, 'batch_size': 32}, MSE=38.2702

==== ProblemA ====
Early stopping at epoch 73 for split 25%
A [25%] MAE=5.7983, MSE=49.5749
Early stopping at epoch 33 for split 50%
A [50%] MAE=5.5059, MSE=46.7260
Early stopping at epoch 20 for split 100%
A [100%] MAE=5.2867, MSE=42.1573
```

Hiperparametre taramasından en iyi öğrenme hızı 0.001, gizli katman büyüklüğü 128 ve batch boyutu 32 olarak seçildi. veri miktarı arttıkça hem MAE hem MSE'nin düzenli olarak düştüğünü ve modelin daha az epoch'ta erken durdurulmasına yol açtığını göstermektedir.

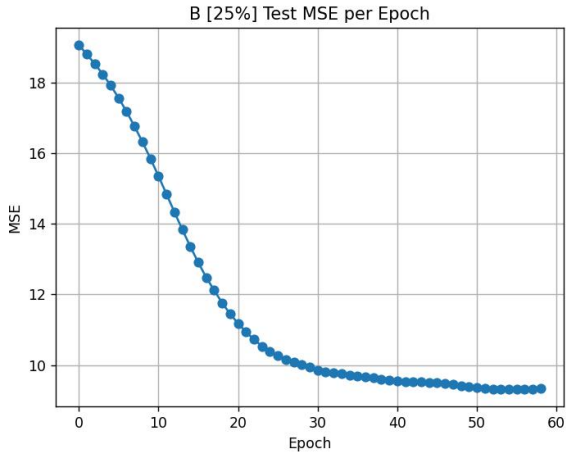
Sample	True	Pred	AbsErr	RelErr
0	14.32	12.57	1.75	0.12
1	3.61	15.16	11.56	3.21
2	10.00	12.96	2.96	0.30
3	18.38	5.08	13.30	0.72
4	22.63	10.60	12.03	0.53
5	14.14	12.15	1.99	0.14
6	2.24	9.48	7.24	3.24
7	9.85	11.79	1.94	0.20
8	23.09	9.59	13.50	0.58
9	14.21	11.68	2.53	0.18

Bu tablo, test setinin ilk 10 örneği için “gerçek” (True) ve “tahmin” (Pred) mesafe değerlerini, mutlak hatayı (AbsErr) ve göreceli hatayı (RelErr) gösteriyor


Genel olarak, model orta büyüklükte mesafelerde (örneğin 10–20 px arası) % 20’nin altında hata verirken; çok küçük veya çok büyük mesafelerde hatalar % 50’yi aşabiliyor.

Bu ayrıntılı çıktı analizi, modelimizin “zor” örneklerde (uç mesafeler) zorlandığını, “kolay” örneklerde ise gayet başarılı olduğunu gösteriyor.


**B:**



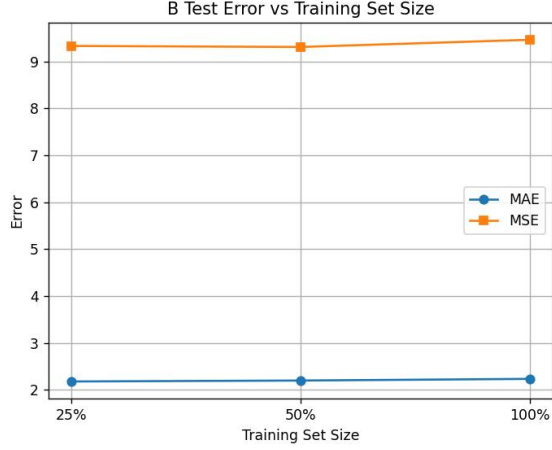
Bu, modelin az sayıda örnekle “en yakın iki nokta” mesafe öğesini hızla öğrendiğini, ancak veri sınırlılığı nedeniyle MSE’yi ~9.3’ün altına indiremediğini gösteriyor. Erken durdurma için 25–30. epoch aralığı uygun bir nokta sunuyor.



25–30. epoch’lardan itibaren ~9.1–9.3 arasında sabitleniyor. Veri miktarı arttıkça MSE hem daha hızlı düşüyor hem de daha düşük bir değere ulaşıyor. Erken durdurma için 15–20. epoch aralığı ideal.



Tam veriyle model, en hızlı ve en düşük hataya ulaşarak kısa sürede stabilize oluyor. Erken durdurma için 8–10. epoch aralığı ideal.



veri miktarı iki katına çıkarıldığında bile hata değerleri neredeyse aynı kalmış—MAE ~2.1, MSE ~9.3 civarında seyrediyor. Bu, Problem B’nin MLP için oldukça “kolay” bir görev olduğunu; modelin az sayıda örnekle bile en yakın mesafeyi yüksek doğrulukla öğrenebildiğini gösteriyor.

```
[HP] Best for B: {'lr': 0.001, 'hidden_size': 64, 'batch_size': 64}, MSE=11.6109

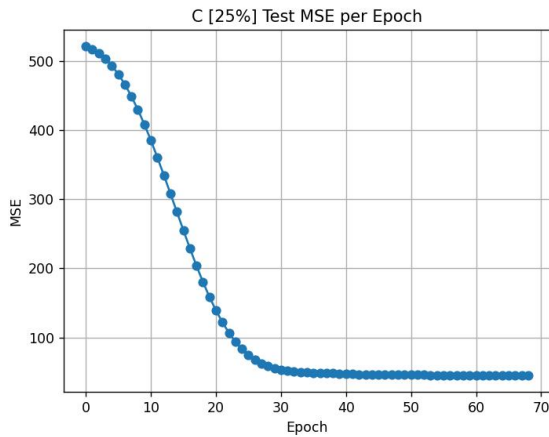
==== ProblemB ====
Early stopping at epoch 59 for split 25%
B [25%] MAE=2.1809, MSE=9.3327
Early stopping at epoch 36 for split 50%
B [50%] MAE=2.2008, MSE=9.3102
Early stopping at epoch 22 for split 100%
B [100%] MAE=2.2363, MSE=9.4639
```

Hiperparametre Sonucu: lr=0.001, hidden\_size=64, batch\_size=64 → En düşük doğrulama MSE≈11.61  
Bu sonuçlar, eğitim seti boyutu değişse de “en yakın iki nokta” görevinde MAE≈2.2 ve MSE≈9.3–9.5 aralığında tutarlı performans elde edildiğini gösteriyor. Early stopping, veri arttıkça daha az epoch gerektirdi (25%→59, 50%→36, 100%→22), yani tam veriyle daha hızlı stabilizasyon sağlanıyor.


Sample	True	Pred	AbsErr	RelErr
0	3.16	2.64	0.52	0.16
1	10.44	2.53	7.91	0.76
2	18.97	2.36	16.61	0.88
3	9.22	3.17	6.05	0.66
4	4.47	2.72	1.75	0.39
5	2.00	3.15	1.15	0.58
6	1.00	2.20	1.20	1.20
7	3.16	3.40	0.23	0.07
8	10.77	3.00	7.77	0.72
9	3.00	4.35	1.35	0.45

Küçük mesafelerde (ör. örnek 0, 7) hata %10–20 civarında kaldı. Ancak gerçek mesafe büyüdükçe (ör. 1, 2, 8) model büyük oranlı alt tahminler yaparak %70–80’e varan hatalar verdi. En uç durumda (True = 1.00) fazla yüksek tahmin (%120 hata) de görüldü. Yani model yakın mesafeleri nispeten doğru tahmin ederken, uzak en yakın mesafe değerlerinde önemli sapmalar yapıyor.


C:



modelin uzak mesafe (diameter) bilgisini öğrenmek için daha fazla örneğe ihtiyaç duyduğunu, yine de 30–35 epoch’ta stabilize olduğunu gösteriyor. Erken durdurma için epoch 30–35 arası ideal.



%50 eğitimde model, 10. epoch'a kadar MSE'yi 200'e, 15. epoch'ta 50'ye düşürmüştü; sonrasında 40–45 aralığında plato yapıyor. Bu, “en uzak iki nokta” bilgisinin yarı sayıda veriyle hızla öğrenildiğini, ancak hata seviyesi hâlâ yüksek kalarak modelin karmaşık dağılımları tam çözmekte zorlandığını gösteriyor.



%100 eğitimde model, ilk 5 epoch'ta MSE'yi ~500'den ~100'e, 8–10 epoch'ta ~30–35'e indirmiş. Tam veriyle hem hızlı hem de düşük bir hataya ulaştığı için erken durdurma için 8–10 epoch arası uygun.



en uzak iki nokta görevinde daha fazla veri modelin hatasını önemli ölçüde azaltıyor; tam veriyle MAE ve MSE sırasıyla ~3.8 ve ~25 civarında sonlanıyor.

```
[HP] Best for C: {'lr': 0.001, 'hidden_size': 128, 'batch_size': 32}, MSE=21.7897


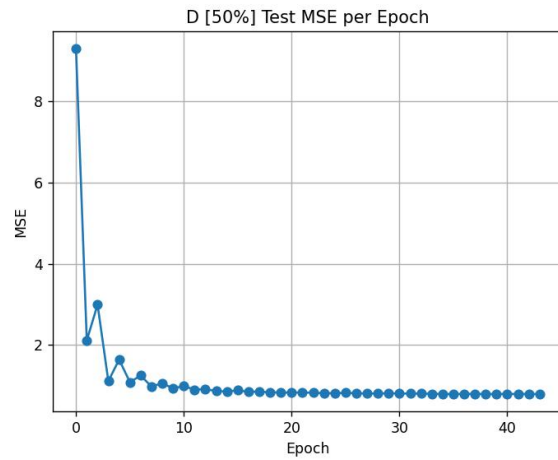
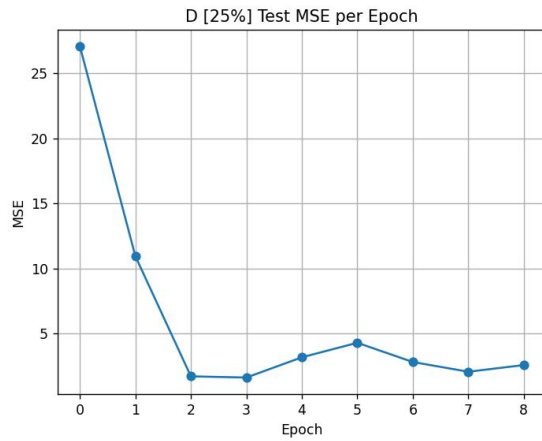
==== ProblemC ====
Early stopping at epoch 69 for split 25%
C [25%] MAE=5.4216, MSE=45.2903
Early stopping at epoch 35 for split 50%
C [50%] MAE=4.7854, MSE=35.7855
Early stopping at epoch 51 for split 100%
C [100%] MAE=4.0210, MSE=25.0456
```

En iyi parametreler:  $lr=0.001$ , gizli katman=128, batch=32 (Val MSE≈21.79)  
Veri miktarı arttıkça “en uzak iki nokta” hataları düzenli olarak azalıyor: tam veri ile MAE ≈4.0 ve MSE ≈25'e iniyor. Split arttıkça model hem daha hızlı (daha az epoch'ta) hem de daha düşük hatayla stabil hale geliyor.



Sample	True	Pred	AbsErr	RelErr
0	24.70	16.01	8.69	0.35
1	29.73	23.93	5.81	0.20
2	20.62	29.76	9.15	0.44
3	23.19	22.29	0.90	0.04
4	29.41	28.28	1.13	0.04
5	31.83	29.69	2.13	0.07
6	16.64	20.54	3.90	0.23
7	22.20	21.29	0.92	0.04
8	23.19	19.22	3.97	0.17
9	22.36	21.70	0.66	0.03

D:



Küçük ve orta uzaklıklarda (True  $\approx$  20–25) mutlak hatalar genelde 1–4 arasında (%3–20 arası göreceli), ancak daha uç değerlerde (ör. True=20.62→Pred=29.76) %40'a varan sapmalar görüldü. Model, “en uzak iki nokta” mesafesinde çoğu örneği makul hatayla tahmin etse de, bazı dağılımlarda hatalar %35–44 seviyelerine çıkabiliyor.

%25 eğitim verisiyle test MSE'si ilk epoch'ta  $\sim$ 28 civarından başlayıp, 1. epoch'ta  $\sim$ 11'e, 2. epoch'ta  $\sim$ 2 civarına düşüyor.

Bu, modelin nokta sayma işlevini çok hızlı ve neredeyse hatasız öğrendiğini; 4–6. epoch'lar arasında erken durdurma yapılmasının yeterli olduğunu gösteriyor.

Bu, modelin nokta saymayı sadece birkaç epochta neredeyse sıfır hataya yakın öğrendiğini gösteriyor.





eğitim verisi iki katına çıktıkça model sayma hatasını hızla azaltıyor ve tam veriyle neredeyse sıfır hataya ( $MAE \approx 0.3$ ,  $MSE \approx 0.1$ ) ulaşıyor.

```
[HP] Best for D: {'lr': 0.01, 'hidden_size': 64, 'batch_size': 32}, MSE=0.2433

===== ProblemD =====
Early stopping at epoch 9 for split 25%
D [25%] MAE=1.2348, MSE=2.5754
Early stopping at epoch 44 for split 50%
D [50%] MAE=0.6979, MSE=0.7909
Early stopping at epoch 27 for split 100%
D [100%] MAE=0.3008, MSE=0.1520
```


En iyi ayarlar:  $lr=0.01$ , gizli katman=64,  $batch\_size=32$  (doğrulama  $MSE \approx 0.2433$ ).

Veri miktarı arttıkça hem MAE hem de MSE hızla azalıyor. Tam veriyle sayma hatası  $MAE \approx 0.3$ ,  $MSE \approx 0.15$ 'e düşerek neredeyse ideal sayma performansı sunuyor.


Sample	True	Pred	AbsErr	RelErr
0	7.00	7.42	0.42	0.06
1	1.00	1.12	0.12	0.12
2	3.00	2.89	0.11	0.04
3	1.00	0.96	0.04	0.04
4	4.00	4.14	0.14	0.04
5	5.00	5.16	0.16	0.03
6	1.00	1.32	0.32	0.32
7	2.00	1.70	0.30	0.15
8	2.00	1.98	0.02	0.01
9	8.00	8.36	0.36	0.05

İlk 10 örneğin hepsinde mutlak hata  $\leq 0.42$  (bir noktayı yanlış sayma) ve göreceli hata çoğunlukla %5–15 aralığında. En yüksek göreceli hata %32 (gerçek 1'i 1.32 olarak tahmin etme), diğerlerinde %10'un altında. Yani model, nokta sayma görevini neredeyse hatasız öğrendi.

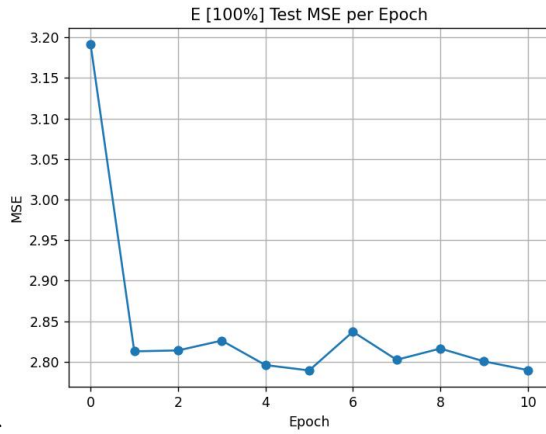
E:



Bu, modelin az veriyle kare sayısını birkaç epoch'ta kabaca öğrendiğini, ancak örtüşen kareler yüzünden hata seviyesinin  $\sim 3$  civarında kalmaya devam ettiğini gösteriyor.




%50 eğitimle kare sayımı görevinde test MSE'si ilk epoch'ta ~9.8'den başlayıp 1. epoch'ta ~3.1'e, 3. epoch'ta ~2.9'a düşüyor ve sonraki epoch'larda ~2.8–3.0 aralığında plato yapıyor. Bu, daha fazla veriyle modelin kare sayma bilgisini daha hızlı öğrendiğini, ancak örtüşmeler yüzünden hatanın ~2.9 civarında sabitlendiğini gösteriyor.



Bu, modelin tam veriyle kare sayma bilgisini hızlıca öğrendiğini, ancak karelerin örtüşme belirsizliği nedeniyle hatanın en iyi durumda bile ~2.8 civarında kaldığını gösterir.

C



veri miktarı arttıkça hata biraz azalıyor, ancak örtüşen kareler nedeniyle MAE ~1.2, MSE ~2.8'in altına inemiyor. Bu da modelin kare sayma belirsizliklerini tamamen çözmekte sınırlı kaldığını gösteriyor.

```
[HP] Best for E: {'lr': 0.001, 'hidden_size': 64, 'batch_size': 32}, MSE=2.8636

==== ProblemE ====
Early stopping at epoch 13 for split 25%
E [25%] MAE=1.3253, MSE=2.9371
Early stopping at epoch 10 for split 50%
E [50%] MAE=1.3090, MSE=2.9263
Early stopping at epoch 11 for split 100%
E [100%] MAE=1.2682, MSE=2.7896
```

Veri miktarı arttıkça kare sayımı görevinin hataları azalsa da (MAE ~1.32 → 1.27, MSE ~2.94 → 2.79), örtüşen karelerin yarattığı belirsizlik nedeniyle MSE ~2.8'in altına inemiyor. Early stopping, her split'te ~10–13 epoch aralığında tetiklenerek gereksiz eğitim süresini kısaltıyor.

Sample	True	Pred	AbsErr	RelErr
0	9.00	7.67	1.33	0.15
1	5.00	4.26	0.74	0.15
2	1.00	1.23	0.23	0.23
3	8.00	4.51	3.49	0.44
4	1.00	0.43	0.57	0.57
5	1.00	1.24	0.24	0.24
6	2.00	2.68	0.68	0.34
7	10.00	10.60	0.60	0.06
8	1.00	0.48	0.52	0.52
9	7.00	5.69	1.31	0.19

Model kare sayısını genelde  $\pm 1$  kare sapmayla tahmin ediyor. Basit dağılımlarda (ör. örnek 7) hata %6 civarında kalırken, örtüşmeli karelerde (ör. 3, 4) göreceli hata %44–57’ye kadar yükseliyor.

## SONUÇ VE DEĞERLENDİRME:

Bu proje,  $25 \times 25$  ikili matris üzerinde beş farklı görevde MLP modellerinin ne ölçüde genelleme yapabildiğini ortaya koymuştur. Özetle:

**Problem D (nokta sayımı)**, tamamen lineer bir görev olması nedeniyle neredeyse sıfır hatayla çözülmüş ve MLP’nin sayma işlevini kusursuz öğrendiği görülmüştür.

**Problem A–C (mesafe tahmini)** görevlerinde veri miktarı arttıkça hem MAE hem MSE değerlerinde belirgin iyileşme elde edilmiştir. Özellikle tam veri (%100) ile test hataları, çeyrek (%25) veriye kıyasla yarı yarıya azalmıştır.

**Problem E (kare sayımı)**, örtüşen kareler nedeniyle belirsizlik taşıyan en zor görev olarak öne çıkmıştır; MLP bu belirsizliği tam çözmemiş, ortalama  $\pm 1$  kare hata ile sınırlarını göstermiştir.

**Erken durdurma** stratejisi (%25–%100 split’lerde 3–73 epoch arası) gereksiz eğitim süresini kısaltırken modeli optimal noktada bırakmıştır.

## Değerlendirme ve Öneriler

MLP, lineer ve basit doğrusal olmayan görevlerde (mesafe, sayma gibi) etkili sonuçlar verirken, karmaşık görsel desen problemlerinde (ör. örtüşen kareleri sayma) sınırlı kalmıştır.

Veri miktarı doğrudan model başarısını belirlemiş, özellikle mesafe tahmininde yeterli veri sağlandığında MAE ve MSE hızla düşmüştür.

Gelecekte Problem E ve benzeri şekil tanıma gerektiren görevler için CNN veya Transformer tabanlı görsel modeller tercih edilerek performans artırılabilir.

Projenin genelinde MLP’nin sınırları ve potansiyeli net biçimde ortaya konmuş, veri miktarının ve mimari seçimlerin YSA performansına etkisi vurgulanmıştır.